FUNDAMENTOS E TÉCNICAS EM CIÊNCIAS DE DADOS

PROF. JOSENALDE OLIVEIRA

josenalde.oliveira@eaj.ufrn.br https://github.com/josenalde/datascience

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS - UFRN

Combinando datasets com CONCAT. Por exemplo, os datasets do World Happiness de 2015, 2016, 2017

```
df_15 = pd.read_csv('../datasets/wh2015.csv')
df_16 = pd.read_csv('../datasets/wh2016.csv')
df_17 = pd.read_csv('../datasets/wh2017.csv')
```

Vamos supor nomes das colunas iguais nos datasets, mas também precisamos considerar nomes diferentes e como irá se comportar ao fazer o CONCAT. Para simplificar, iremos extrair apenas as 5 primeiras linhas de cada dataset, e criar uma coluna YEAR em cada um

	Country	Region	Happiness Rank	Happiness Score	Standard Error
0	Switzerland	Western Europe	1	7.587	0.03411
1	Iceland	Western Europe	2	7.561	0.04884
2	Denmark	Western Europe	3	7.527	0.03328
3	Norway	Western Europe	4	7.522	0.03880
4	Canada	North America	5	7.427	0.03553

df_	16.head()				
Co	ountry Reg	Jion Happiness Rank	Happiness Score	Confid	ower ence erval
1	df_17.he	ead()			
	ſ				
	Country	Happiness.Ran	k Happiness	.Score	Whisker.high
0	Norway		1	7.537	7.594445

Combinando datasets com CONCAT. Por exemplo, os datasets do World Happiness de 2015, 2016, 2017

```
df_15.head()
head_15 = df_15.head()
head_15 = head_15.iloc[:,0:5]
head_15['year'] = 2015
head_15
```

1	head_16 = df_16.head()
2	head_16 = head_16.iloc[:,0:5]
3	head_16['year'] = 2016
4	head_16

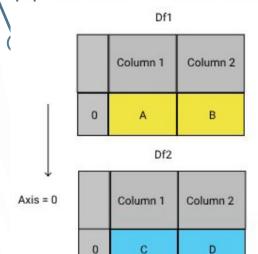
	Country	Region	Happiness Rank	Happiness Score	Standard Error	year
0	Switzerland	Western Europe	1	7.587	0.03411	2015
1	Iceland	Western Europe	2	7.561	0.04884	2015
2	Denmark	Western Europe	3	7.527	0.03328	2015
3	Norway	Western Europe	4	7.522	0.03880	2015
4	Canada	North America	5	7.427	0.03553	2015

	Country	Region	Happiness Rank	Happiness Score	Lower Confidence Interval	year
0	Denmark	Western Europe	1	7.526	7.460	2016
1	Switzerland	Western Europe	2	7.509	7.428	2016
2	Iceland	Western Europe	3	7.501	7.333	2016
3	Norway	Western Europe	4	7.498	7.421	2016
4	Finland	Western Europe	5	7.413	7.351	2016

```
1 head_17 = df_17.head()
2 head_17 = head_17.iloc[:,0:5]
3 head_17['year'] = 2017
4 head_17
```

	Country	Happiness.Rank	Happiness.Score	Whisker.high	Whisker.low	year
0	Norway	1	7.537	7.594445	7.479556	2017
1	Denmark	2	7.522	7.581728	7.462272	2017
2	Iceland	3	7.504	7.622030	7.385970	2017
3	Switzerland	4	7.494	7.561772	7.426227	2017
4	Finland	5	7.469	7.527542	7.410458	2017

Combinando datasets com CONCAT. Pode ser registros (linhas) juntas (o mais comum), ou 'lado a lado'



	Column 1	Column 2
0	A	В
0	С	D

Concatenated

	Df1	, –	Df2
	Column 1		Column 2
0	A	0	В
1	С	1	D

	Concaten	ateu
	Column 1	Column 2
0	А	В
1	С	D

Concatenated

Combinando datasets com CONCAT. Pode ser registros (linhas) juntas (o mais comum), ou 'lado a lado'

```
df_15_16 = pd.concat([head_15.iloc[:,[0,3,5]], head_16.iloc[:,[0,3,5]]], axis=0)
df_15_16
```

	Country	Happiness Score	year
0	Switzerland	7.587	2015
1	Iceland	7.561	2015
2	Denmark	7.527	2015
3	Norway	7.522	2015
4	Canada	7.427	2015
0	Denmark	7.526	2016
1	Switzerland	7.509	2016
2	Iceland	7.501	2016
3	Norway	7.498	2016
4	Finland	7.413	2016

1	df_15_16 = pd.concat([head_15.iloc[:,[0,3,5]], head_16.iloc[:,[0,3,5]]], axis=0,	ignore_index=True)
	df 15 16	

	Country	Happiness Score	year							
0	Switzerland	7.587	2015							
1	Iceland	7.561	2015							
2	Denmark	7.527	2015							
3	Norway	7.522	2015							
4	Canada	7.427	2015	1		_h = pd.concat	([head	d_15.iloc[:,[0,3,5]], he	ad_16.
5	Denmark	7.526	2016	2	df_15_16	5_h				
6	Switzerland	7.509	2016		Country	Happiness Score	year	Country	Happiness Score	year
7	Iceland	7.501	2016	0	Switzerland	7.587	2015	Denmark	7.526	2016
8	Norway	7.498	2016	1	Iceland	7.561	2015	Switzerland	7.509	2016
9	Finland	7.413	2016	2	Denmark	7.527	2015	Iceland	7.501	2016
				3	Norway	7.522	2015	Norway	7.498	2016

Caso haja a junção vertical com colunas não presentes — o Pandas atribui NaN

df_15_16_v = pd.concat([head_15.iloc[:,[0,3,4,5]], head_16.iloc[:,[0,3,5]]], axis=0, ignore_index=True)
df_15_16_v

2015

2015

Denmark

Norway

	Country	Happiness Score	Standard Error	year	
0	Switzerland	7.587	0.03411	2015	
1	Iceland	7.561	0.04884	2015	
2	Denmark	7.527	0.03328	2015	
3	Norway	7.522	0.03880	2015	
4	Canada	7.427	0.03553	2015	
5	Denmark	7.526	NaN	2016	
6	Switzerland	7.509	NaN	2016	
7	Iceland	7.501	NaN	2016	
8	Norway	7.498	NaN	2016	
9	Finland	7.413	NaN	2016	

		Year	Country	Happiness Score	Standard Error		Country	Happiness	Sco	ore Y	Year
	0	2015	Switzerland	7.587	0.03411	0	Denmark		7.5	526 2	2016
	1	2015	Iceland	7.561	0.04884	1	Switzerland		7.5	509 2	2016
	2	201 5	Denmark	7.527	0.03328	2	Iceland		7.5	501 2	2016
	3	2015	Norway	7.522	0.03880						

•		Year	Country	Happiness Score	Standard Error	c	ountry Ha	ppiness Sco	re	Year	r
	0	Year 2015	Country Switzerland	Happiness Score			country Ha			Year 2016.0	
	0		-		0.03411	[7.5	526		0

0.03328

0.03880

Iceland

NaN

axis=1

7.527

7.522

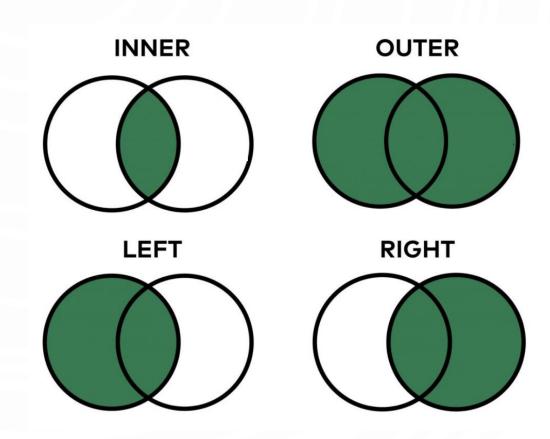
7.501 2016.0

NaN

NaN

Outro método interessante é o MERGE, que atua apenas horizontalmente (axis=1), com 2 dataframes por vez É eficiente, interessante para grandes datasets – define flexibilidade em como os dados são combinados Outer, Inner, Left, Right


	pd.concat()	pd.merge()
Default Join Type	Outer	Inner
Can Combine More Than Two Dataframes at a Time?	Yes	No
Can Combine Dataframes Vertically (axis=0) or Horizontally (axis=1)?	Both	Horizontally
Syntax	Concat (Vertically) concat([df1,df2,df3]) Concat (Horizontally) concat([df1,df2,df3], axis = 1)	Merge (Join on Columns) merge(left = df1, right = df2, how = 'join_type', on = 'Col') Merge (Join on Index) merge(left = df1, right = df2, how = 'join_type', left_index = True, right_index = True)



Outro método interessante é o MERGE, que atua apenas horizontalmente (axis=1), com 2 dataframes por vez É eficiente, interessante para grandes datasets – define flexibilidade em como os dados são combinados Outer, Inner, Left, Right

A cláusula INNER JOIN permite usar um operador de comparação para comparar os valores de colunas provenientes de tabelas associadas. Por meio desta cláusula, os registros de duas tabelas são usados para que sejam gerados os dados relacionados de ambas.

A cláusula LEFT JOIN permite obter não apenas os dados relacionados de duas tabelas, mas também os dados não relacionados encontrados na tabela à esquerda da cláusula JOIN. Caso não existam dados relacionados entre as tabelas à esquerda e a direita do JOIN, os valores resultantes de todas as colunas da lista de seleção da tabela à direita serão nulos. Ao contrario do LEFT JOIN, a cláusula RIGHT JOIN retorna todos os dados encontrados na tabela à direita de JOIN. Caso não existam dados associados entre as tabelas à esquerda e à direita de JOIN, serão retornados valores nulos.



Outro método interessante é o MERGE, que atua apenas horizontalmente (axis=1), com 2 dataframes por vez É eficiente, interessante para grandes datasets – define flexibilidade em como os dados são combinados Outer, Inner, Left, Right

	Country	Happiness Rank	Year		Country	Happiness	Rank	Year
2	Denmark	3	2015	2	Iceland		3	2016
3	Norway	4	2015	3	Norway		4	2016
4	Canada	5	2015	4	Finland		5	2016

pd.merge(left=three_2015, right=three_2016, on="Country")

	Country	Happiness Rank_x	Year_x	Happiness Rank_y	Year_y
0	Norway	4	2015	4	2016

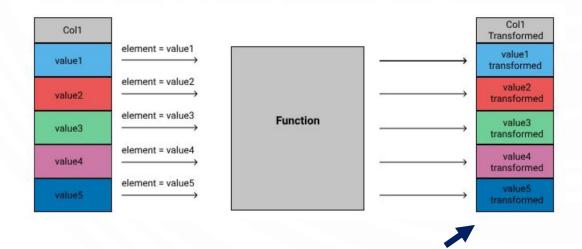
Outro método interessante é o MERGE, que atua apenas horizontalmente (axis=1), com 2 dataframes por vez É eficiente, interessante para grandes datasets – define flexibilidade em como os dados são combinados Outer, Inner, Left, Right

	Country	Happiness	Rank	Year		Cou	ntry H	Iappines	s Rank	Year	
2	Denmark		3	2015		2 lce	eland		3	2016	
3	Norway		4	2015		3 No	rway		4	2016	
4	Canada		5	2015		4 Fir	nland		5	2016	
pc	d.merge	left=thi how='lef	_		_		_	-	2015'	,' 20	16')
pc		how='le	Et',	on='C	oun	try',s	uffix	xes=('_			
0			Et',	on='C	oun	try',s	uffix	xes=('_		Yea	r_201
	Country	how='le	Et',	on='C	oun	try',s	uffix	xes=('_	nk_2016	Yea:	r_201 Nal
0	Country Denmark	how='le	Et',	on='C	oun	2015	uffix	xes=('_	nk_2016 NaN	Yea:	

	Country I	Happiness Rank	Year		Country Hap	piness Rank	Year	
2	Denmark	3	2015	2	Iceland	3	2016	
3	Norway	4	2015	3	Norway	4	2016	
4	Canada	5	2015	4	Finland	5	2016	
5	Finland	6	2015					
				how='le	s = ('_2015	','_2016'))		
C	ountry_2015	Happiness Rank_	2015	Year_2015	Country_2016	Happiness R	ank_2016	Year_20
	Denmark		0	0015	Iceland			0011
2	Denmark		3	2015	iceianu		3.0	2016
2	Norway		4	2015	Norway		3.0 4.0	
								2016
	Norway		4	2015	Norway		4.0	2016 2016

Gerar transformação de colunas a partir de mapeamentos: apply, map, applymap, melt No dataset em estudo, qual feature contribui mais para o Happiness Score (target variable)

	Country	Region	Happiness Rank	Happiness Score	Standard Error	Economy	Family	Health	Freedom	Trust	Generosity
0	Switzerland	Western Europe	1	7.587	0.03411	1.39651	1.34951	0.94143	0.66557	0.41978	0.29678
1	Iceland	Western Europe	2	7.561	0.04884	1.30232	1.40223	0.94784	0.62877	0.14145	0.43630
2	Denmark	Western Europe	3	7.527	0.03328	1.32548	1.36058	0.87464	0.64938	0.48357	0.34139
3	Norway	Western Europe	4	7.522	0.03880	1.45900	1.33095	0.88521	0.66973	0.36503	0.34699
4	Canada	North America	5	7.427	0.03553	1.32629	1.32261	0.90563	0.63297	0.32957	0.45811



Gerar transformação de colunas a partir de mapeamentos: apply, map, applymap, melt No dataset em estudo, qual feature contribui mais para o Happiness Score (target variable)

```
def label(element, x):
    if element > x:
        return 'High' # ou 1
    else:
        return 'Low' # ou 0

# para uma função com o valor de comparação já definido, map() funciona bem

""

def label(element):
    if element > 1:
        return 1
    else:
        return 0

df_15['economy_impact'] = df_15['economy'].map(label)

df_15['economy_impact'] = df_15['economy'].apply(label, x = 1.1)
```

	Country	Region	Happiness Rank	Happiness Score	Standard Error	economy	Family	Health (Life Expectancy)	Freedom	Trust (Government Corruption)	Generosity	Dystopia Residual	economy_impact
0	Switzerland	Western Europe	1	7.587	0.03411	1.39651	1.34951	0.94143	0.66557	0.41978	0.29678	2.51738	High
1	Iceland	Western Europe	2	7.561	0.04884	1.30232	1.40223	0.94784	0.62877	0.14145	0.43630	2.70201	High

Para aplicar em múltiplas colunas, substituindo seus valores numéricos por variáveis dummy (0/1):

Gerar transformação de colunas a partir de mapeamentos: apply, map, applymap, melt No dataset em estudo, qual feature contribui mais para o Happiness Score (target variable)

- 1 factors_impact = df_15[factors].applymap(label2)
- 1 factors impact

	economy	family	health	freedom	trust	generosity
0	1	1	0	0	0	0
1	1	1	0	0	0	0
2	1	1	0	0	0	0
3	1	1	0	0	0	0
4	1	1	0	0	0	0
153	0	0	0	0	0	0
154	0	0	0	0	0	0
155	0	0	0	0	0	0
156	0	0	0	0	0	0
157	0	0	0	0	0	0

Para aplicar em múltiplas colunas, substituindo seus valores numéricos por variáveis dummy (0/1):

```
1 factors_impact.apply(pd.value_counts)
```

	economy	family	health	freedom	trust	generosity
0	92	69	156	158.0	158.0	158.0
1	66	89	2	NaN	NaN	NaN

```
def v_counts(col):
    n = col.value_counts()
    d = col.size
    return n/d

factors_impact.apply(v_counts)
```

	economy	family	health	freedom	trust	generosity
0	0.582278	0.436709	0.987342	1.0	1.0	1.0
1	0.417722	0.563291	0.012658	NaN	NaN	NaN

Gerar transformação de colunas a partir de mapeamentos: apply, map, applymap, melt No dataset em estudo, qual feature contribui mais para o Happiness Score (target variable)

1 2	<pre>top_two = df_15.head(2) top_two</pre>												
	Country	Region	Happiness Rank	Happiness Score	Standard Error	economy	family	health	freedom	trust	generosity	Dystopia Residual	economy_impact

Country	Region	Happiness Rank	Happiness Score	Standard Error	economy	family	health	freedom	trust	generosity	Dystopia Residual	economy_impact
0 Switzerland	Western Europe	1	7.587	0.03411	1.39651	1.34951	0.94143	0.66557	0.41978	0.29678	2.51738	High
1 Iceland	Western Europe	2	7.561	0.04884	1.30232	1.40223	0.94784	0.62877	0.14145	0.43630	2.70201	High

pd.melt(top_two, id_vars=['Country'], value_vars=['economy', 'family', 'health'])

	Country	variable	value
0	Switzerland	economy	1.39651
1	Iceland	economy	1.30232
2	Switzerland	family	1.34951
3	Iceland	family	1.40223
4	Switzerland	health	0.94143
5	Iceland	health	0.94784