FUNDAMENTOS E TÉCNICAS EM CIÊNCIAS DE DADOS

PROF. JOSENALDE OLIVEIRA

josenalde.oliveira@eaj.ufrn.br
https://github.com/josenalde/datascience

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS - UFRN

UM POUCO SOBRE **APRENDIZAGEM** DE MÁQUINA

Machine Learning - ML

Ser humano estabelece conexões para lidar com coisas novas

Similaridade pode ser óbvio para o humano, mas não para computadores

Máquinas operam sobre tarefas frequentes, com alto volume e velocidade

Desafio: máquinas serem ensinadas e depois aprenderem 'sozinhas'

UM POUCO SOBRE **APRENDIZAGEM** DE MÁQUINA

Machine Learning - ML

Como uma criança aprende que ambos são dinossauros?

E aqui?

UM POUCO SOBRE **INTELIGÊNCIA** ARTIFICIAL

The Rebelling Robots, R.U.R (1920 – Karel Capek)

Eu, Robô (2004)
Isaac Asimov (1950)

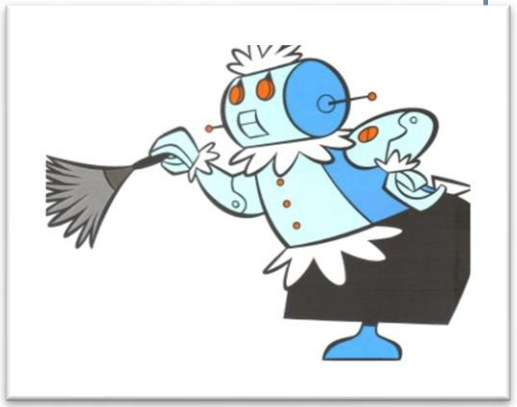

Rosie (Rosey) – Jetsons
62-63 / 84-87

- **Inteligência artificial como meio e não como fim**
- **Inteligência artificial ajuda a encontrar respostas, mas ainda está longe de saber fazer as perguntas!**

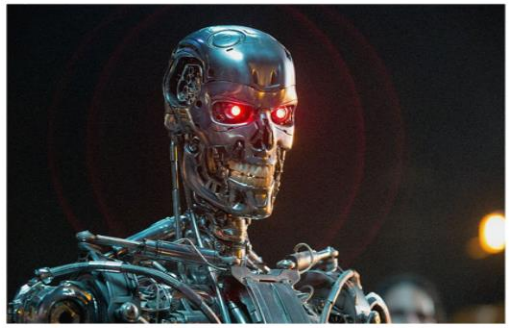

Exterminador T-800 (1984)

UM POUCO SOBRE **INTELIGÊNCIA** ARTIFICIAL

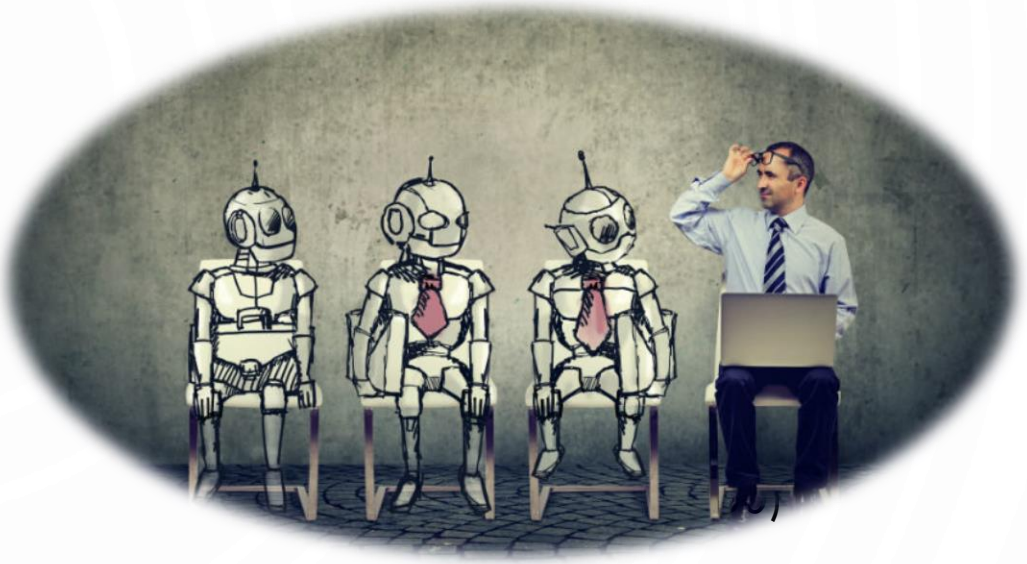

Será que isto será possível?

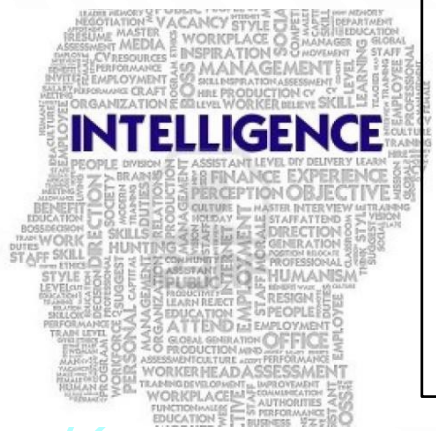

- **Prover as máquinas com capacidade de tomarem decisões inteligentes**
  - **(certa autonomia)**
- **Neste contexto, inteligência como capacidade de tomar a melhor decisão possível dada a informação disponível, com a capacidade de se adaptar a novas situações**

UM POUCO SOBRE **INTELIGÊNCIA** ARTIFICIAL

- Comparemos a autonomia num chão de fábrica, com regras Se...Então
- Com a autonomia necessária a um veículo autônomo

Condicionais: Se obstáculo à frente...pare

Se prateleira fazia...vá para próxima

Ambiente controlado

Quais as necessidades para um carro autônomo?

Desenvolvimento tradicional baseado em regras?

- **Necessidades de reconhecimento/classificação**
- **Predição**

UMA MÁQUINA COM SOFT SKILLS?

- Embora a computação otimize e amplie a adoção de análise (analytics) por meio de variadas técnicas de inferência e predição...
- O conceito aqui está na pessoa com capacidade analítica (negócios), de modo a, com base na manipulação dos dados obter insights que podem trazer algum tipo de vantagem competitiva – competência
- A modelagem pode ser automatizada, mas as pessoas definem os problemas

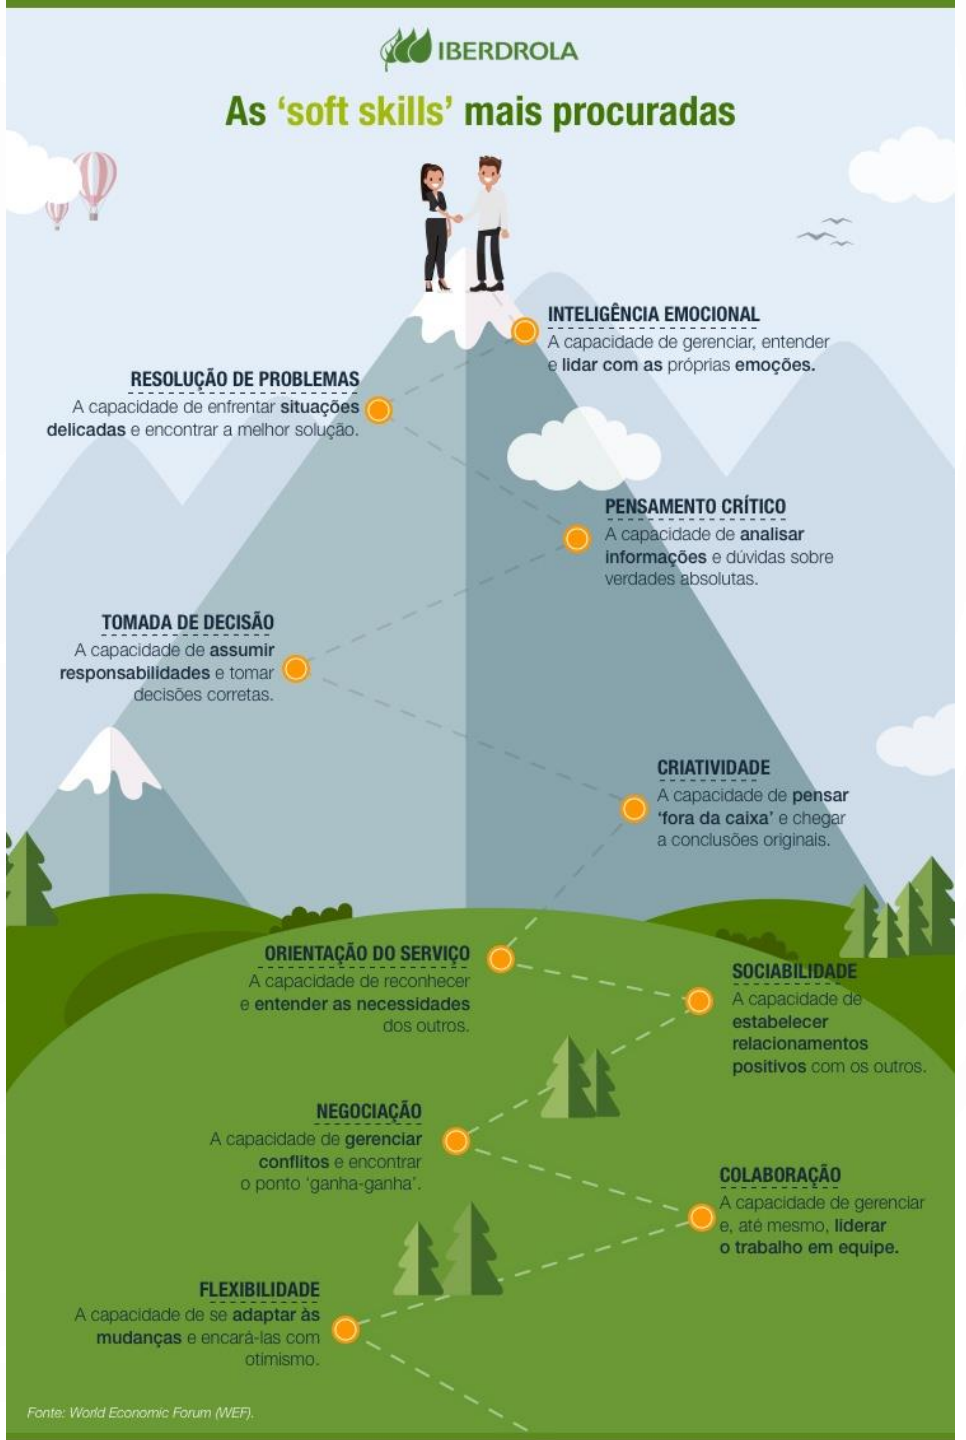

SITUANDO...

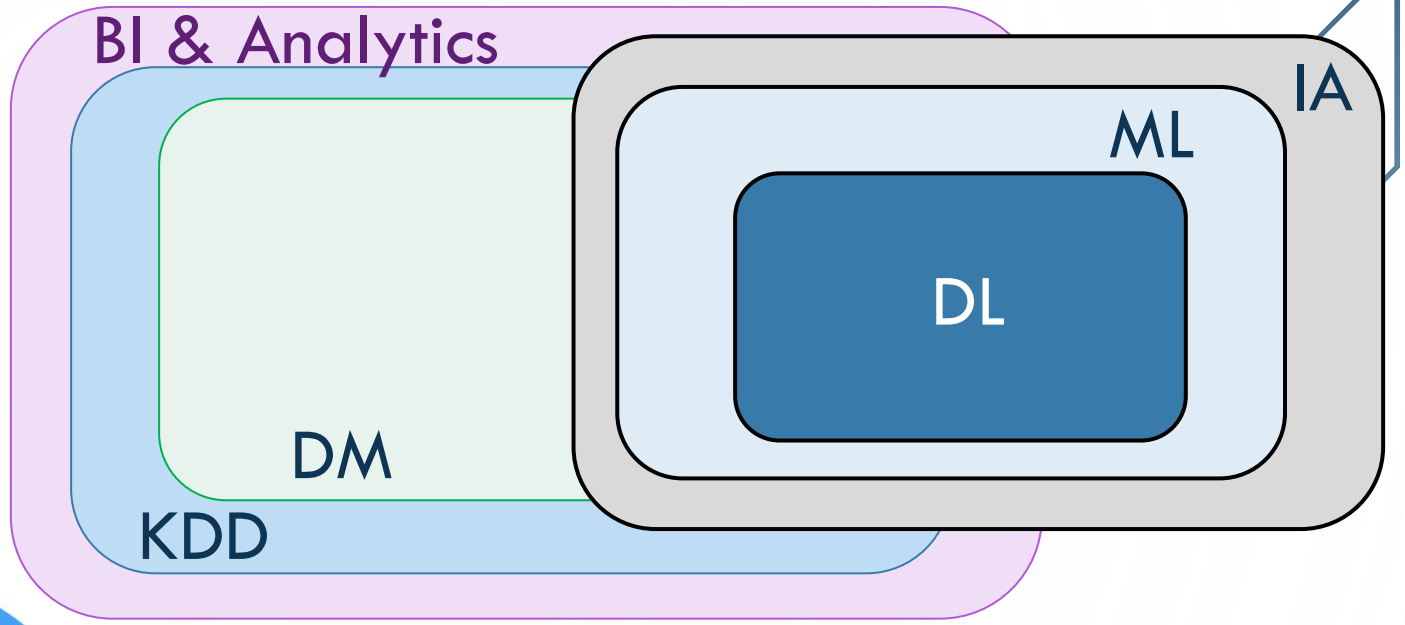

Técnicas que habilitam os computadores a **resolver problemas** que seres considerados inteligentes resolvem.

Subconjunto de técnicas da IA que usam métodos para permitir que as máquinas se aprimorem **a partir de experiências** (dados, por exemplo).

Subconjunto de AM **que combina visão computacional e sistemas de aprendizagem** conjuntamente.

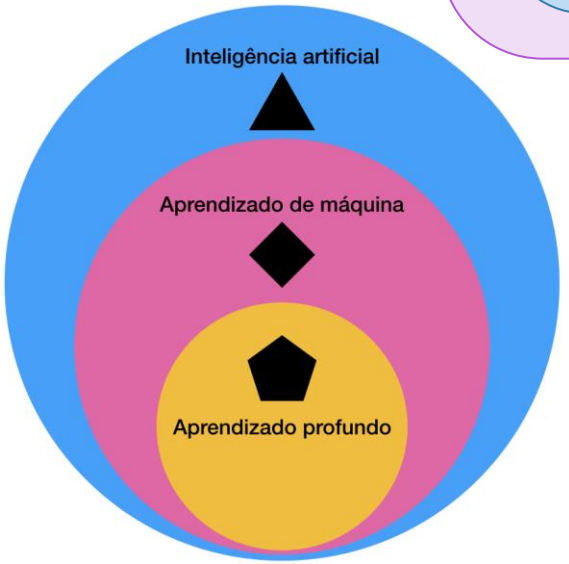

BI: Business Intelligence
DM: Data Mining
KDD: Knowledge Discovery in Databases
DL: Deep Learning (Aprendizado Profundo)
ML: Machine Learning
IA: Inteligência Artificial

KDD E FRAMEWORKS PARA MANIPULAÇÃO DE DADOS

- O ciclo de vida do dado que temos estudado é baseado em frameworks consolidados
- O termo BI remonta à 1958 no artigo de Luhn, H.P.

LUHN, H.P. **A Business Intelligence System**. *IBM Journal of Research and Development*, vol. 2, no. 4, pp. 314-319, Oct. 1958. doi: 10.1147/rd.24.0314

Abstract: an automatic system is being developed to disseminate information to the various sections of any industrial, scientific or government organization. This intelligence system will utilize **data-processing machines for auto-abstracting and auto-encoding of documents and for creating interest profiles for each of the "action points" in an organization**. Both incoming and internally generated documents are automatically abstracted, characterized by **a word pattern**, and sent automatically to appropriate action points. This paper shows the

in finding

who needs to know it

- O KDD (1996) pode ser visto como o framework geral para encontrar informação útil em massas de dados, e o DM é uma etapa do KDD, aplicando algoritmos para extrair padrões

KDD E FRAMEWORKS PARA MANIPULAÇÃO DE DADOS

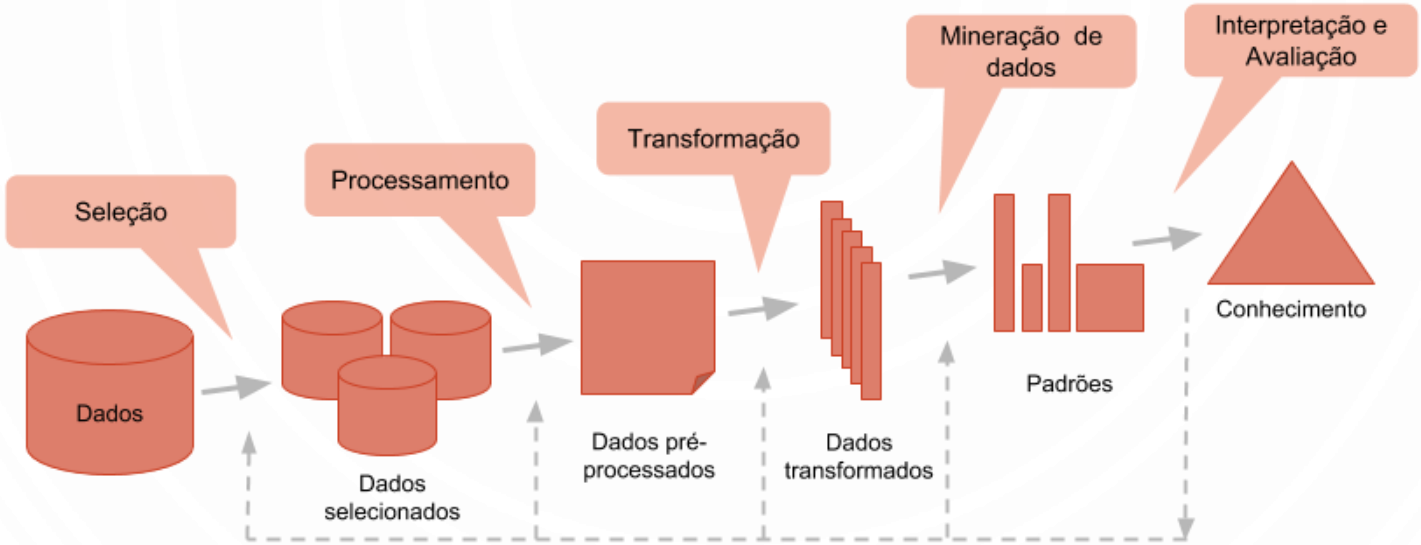

- Fazer o processo de forma estruturada é fundamental, seguindo **etapas, método**
- KDD é o mais antigo, mais conhecido, não foca em negócios ou modelos, mas na descoberta de padrões a partir dos dados
- CRISP-DM é uma das mais usadas e considerada mais completa – genérica e com maior link com o negócio alvo

CRISP-DM

Processo Padrão Inter-Indústrias para Mineração de Dados (1996)
(Daimler Chrysler, SPSS e NCR4)

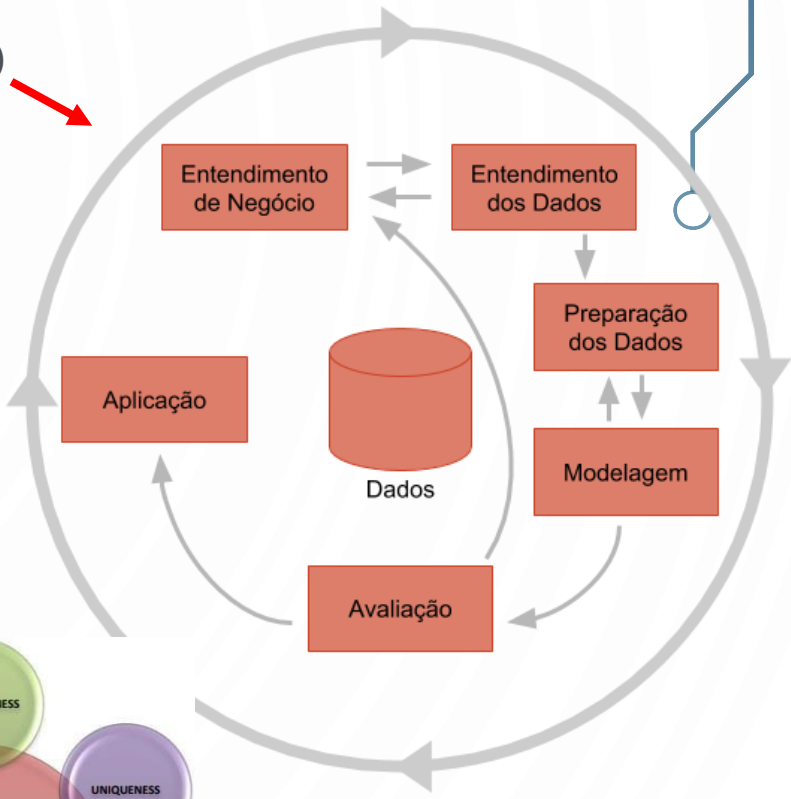

- **Entendimento do negócio:** identificação do problema a ser resolvido – *business-oriented*
  - *Artefatos: background (contexto, como projeto resolve), objetivos e critério de sucesso (métricas)*
- **Entendimento dos dados:** captura (coleta), descrição (o que se entende dos dados), exploração, **qualidade**
- **Preparação dos dados:** criação do *dataset* a partir de *raw data*, seleção, limpeza, transformação, integração – entrada da modelagem
- **Modelagem:** que técnica usar? Projetar testes, construir e avaliar modelos
- **Avaliar:** atende aos objetivos e vai para produção?
- **Aplicação:** é aqui que a empresa faz uso de toda a análise desenvolvida. Apresentação dos resultados da modelagem para a tomada de decisão

DAMA Framework

O PESO DAS FASES...

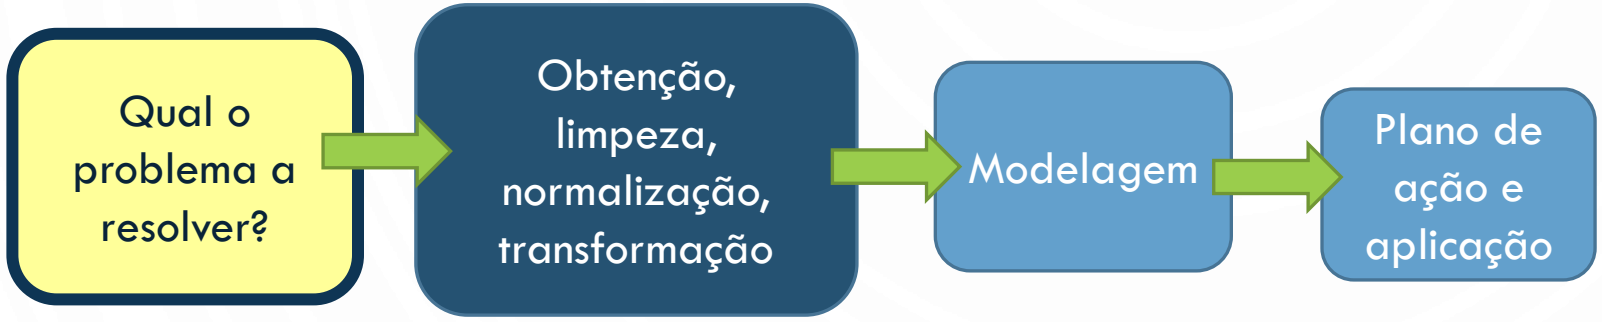

Boa parte do tempo aqui!

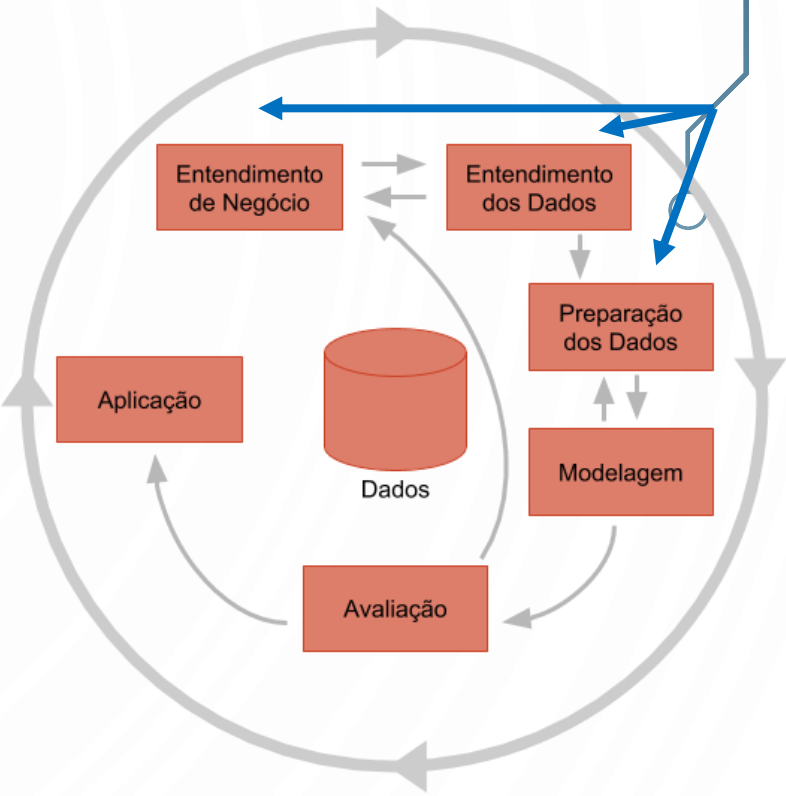

BIG PICTURE DO PROJETO DE DATA SCIENCE

Identificação de disponibilidade, fonte de coleta e tipos de dados

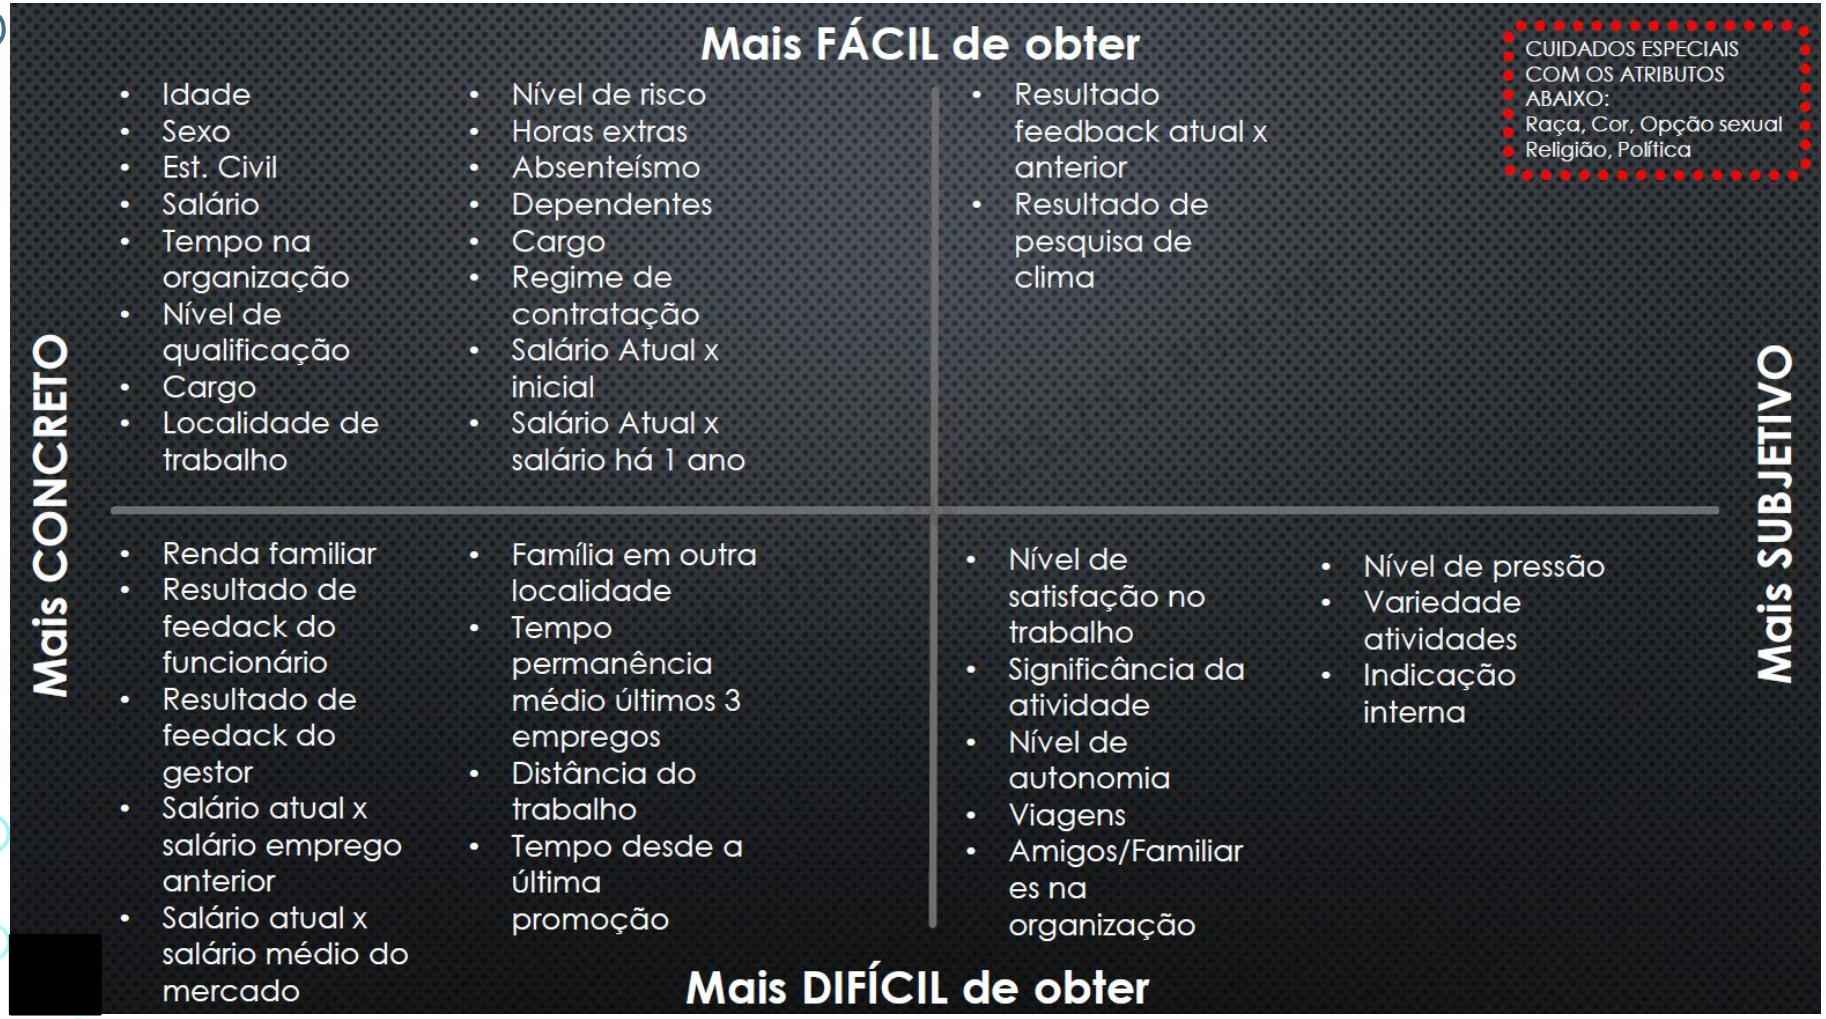

Exemplo baseado em Canvas – Fabiano Castello@IA

BIG PICTURE DO PROJETO DE DATA SCIENCE

Qual o problema a ser resolvido? 1

Fontes dos Dados 2

Target 4

Produtos de Dados 5

Direcionadores PITCH 6

- Qual a oportunidade?
- O que está buscando?
- Quais vantagens do produto de dados?

Principais Atributos (variáveis) 3

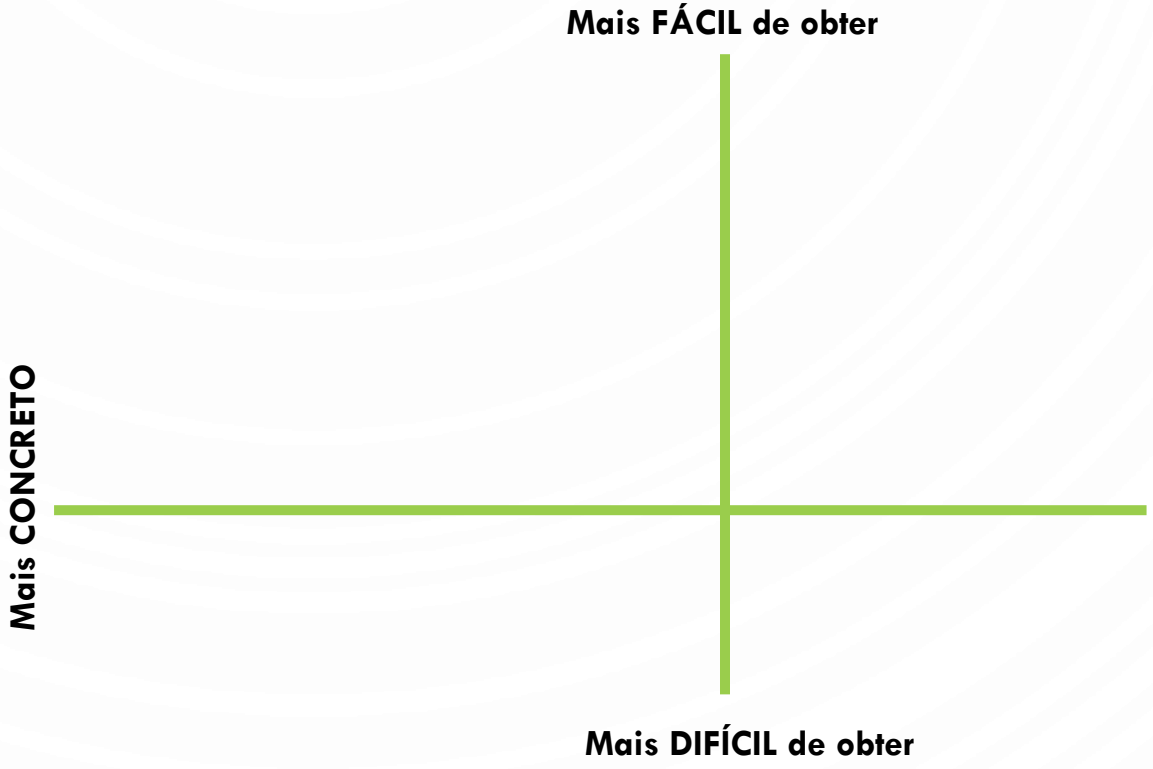

ASPECTOS DE MACHINE LEARNING

- O foco da ML está em ANÁLISE PREDITIVA
- Ferramentas/Técnicas/Algoritmos que fazem 'predições', de forma mais rápida, barata, assertiva e que captam bem o 'novo'

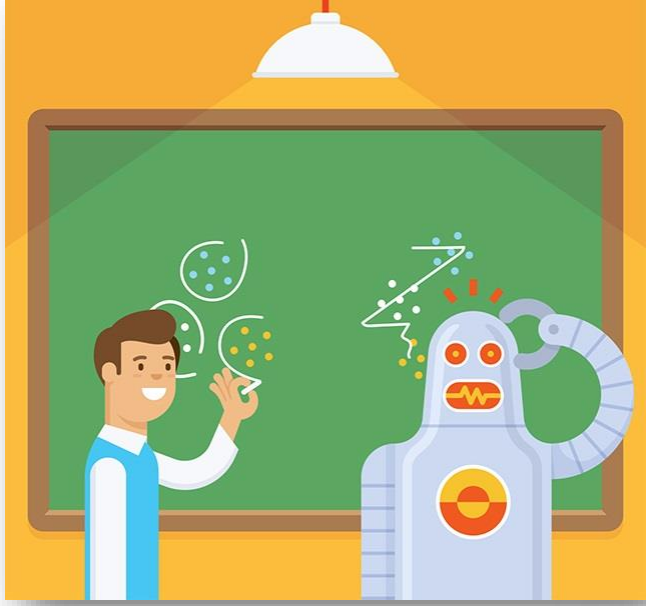

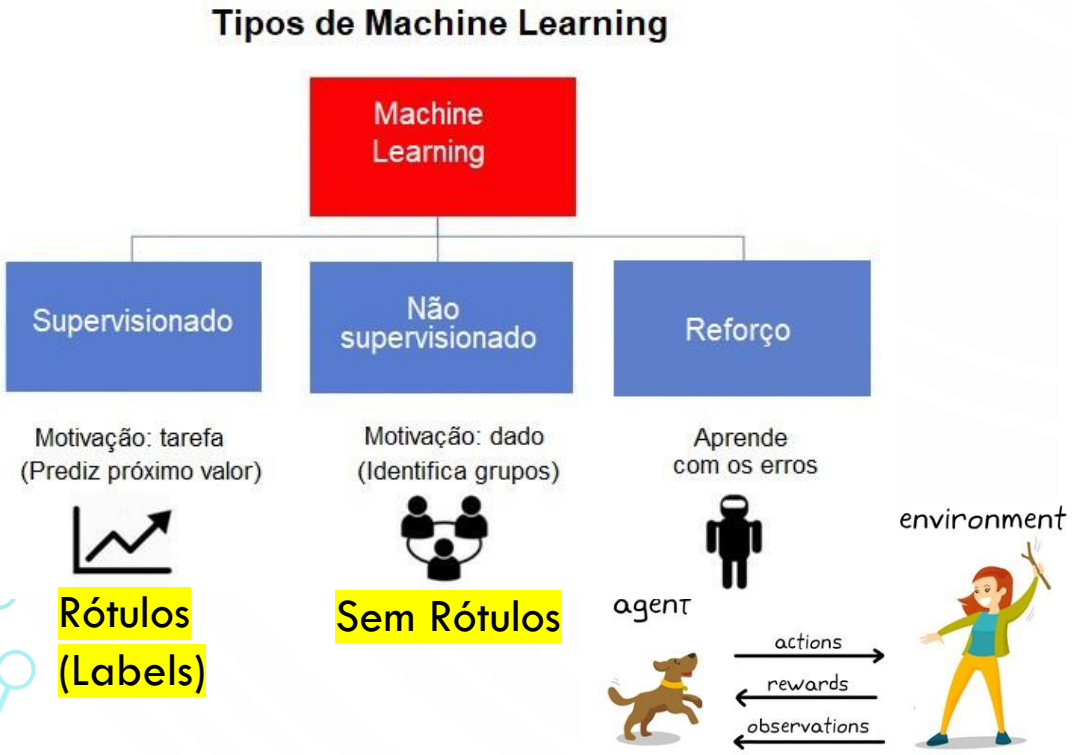

ASPECTOS DE MACHINE LEARNING

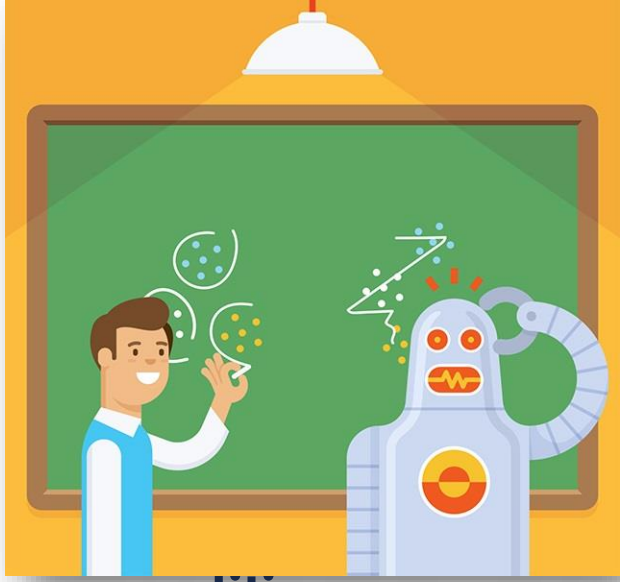

- Um bom projeto de ML tem boa capacidade preditiva
- Acurácia nas decisões (acertos)
- Performance preditiva! Nem sempre a interpretação do processo é simples (pois decisões envolvem processos complexos)
- Em Inferência (regressão por exemplo), a relação entre as variáveis é melhor interpretável, mas usualmente pior performance preditiva

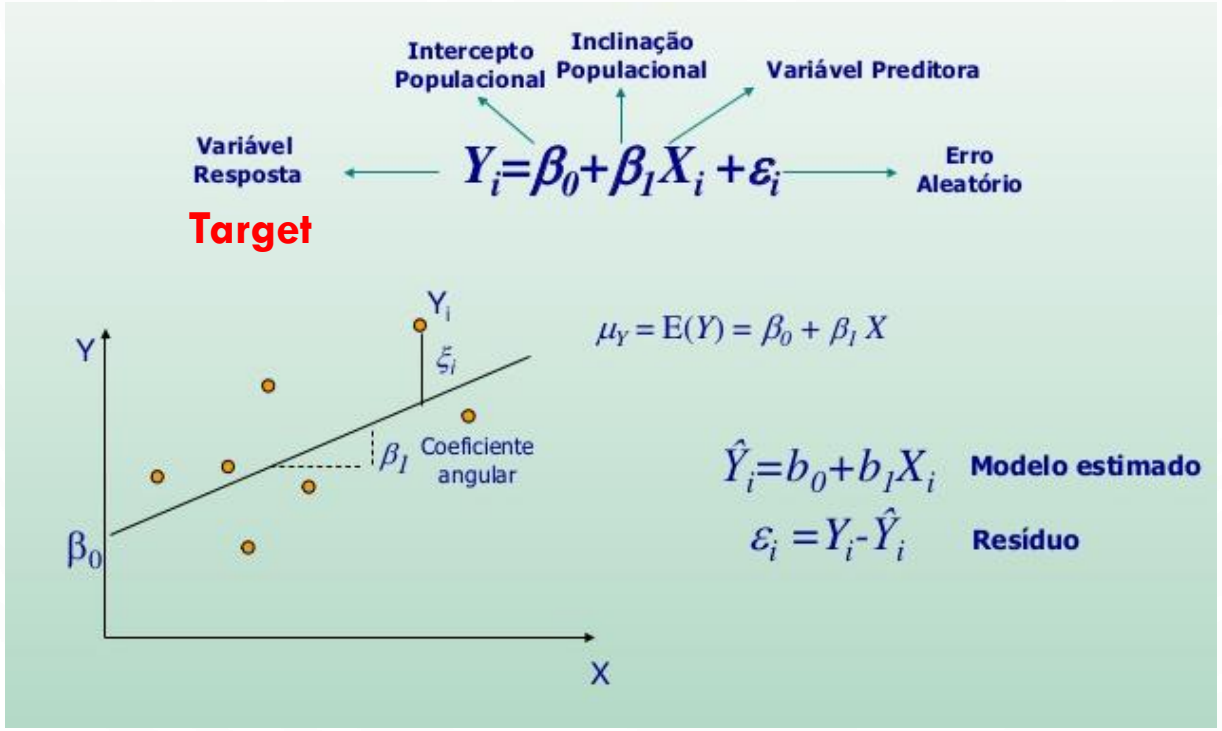

Regressão/Inferência: target quantitativo
Classificação: target qualitativo
Regressão logística: target quantitativo é probabilidade de um evento ocorrer como função de outros fatores.

ASPECTOS DE MACHINE LEARNING

- Regressão logística: target categórico e binário (s/n, 0/1, é/não é)
  - Sucesso/Fracasso, Desligado? (s/n)

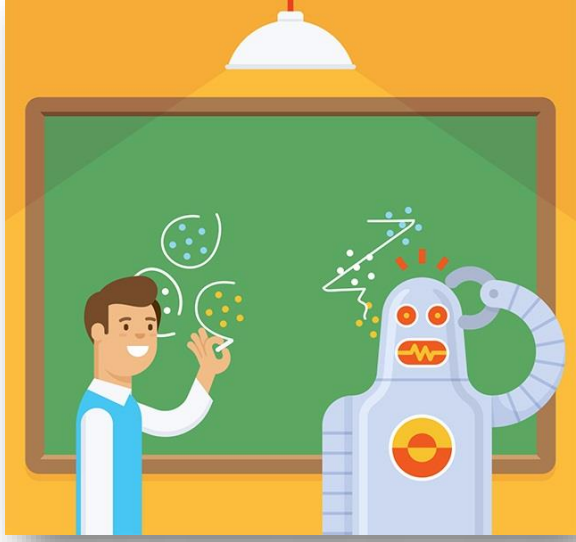

$$ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 x$$

$$=> P = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

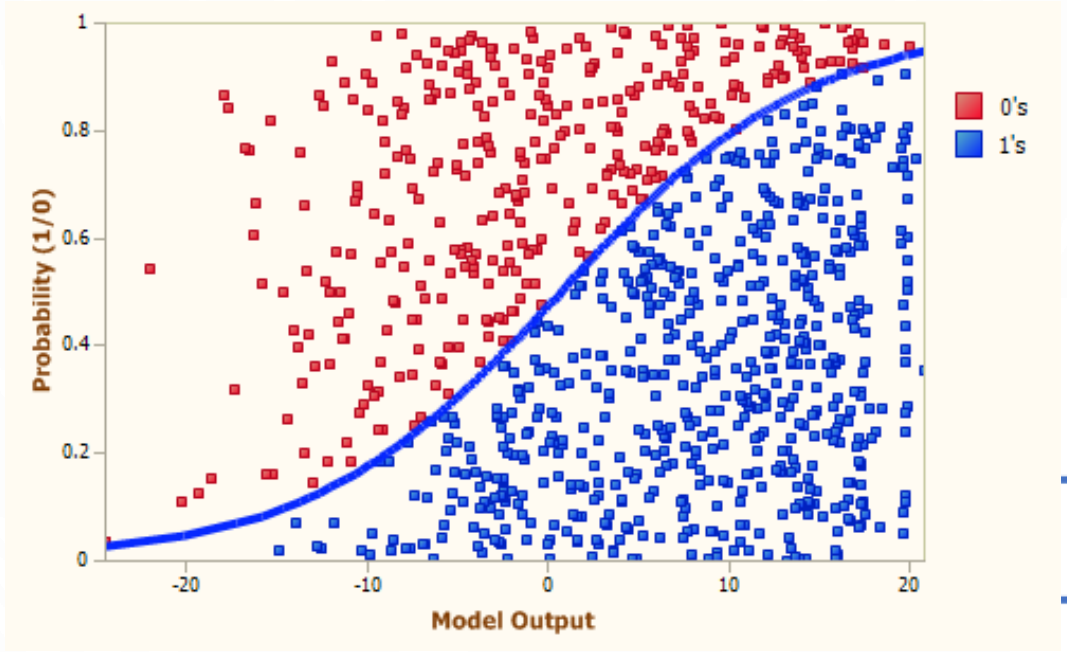

Diferenças

	Linear	Logística
Reta	Reta	Curva - S
Variável Dependente	Continua	Categórica
Interpretação	$\hat{y}$	$\ln\left(\frac{p}{1+p}\right)$

http://neylsoncrepalde.github.io/2019-11-25-regressao_logistica_python/

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html

ASPECTOS DE MACHINE LEARNING

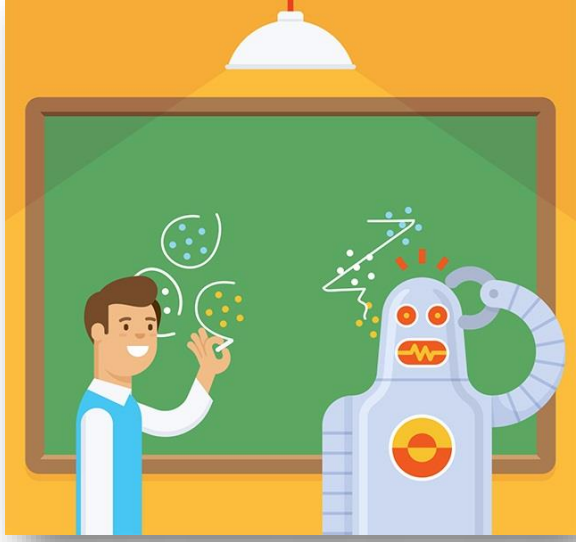

- **Agrupamentos: não supervisionado – maximizar semelhanças (minimizar distâncias) dentro do cluster e maximizar diferenças (maximizar distâncias) entre clusters**

Método K-means é o mais usado

Mas existem vários outros métodos e variantes: Hierarquicos, aglomerativos, incremental etc.

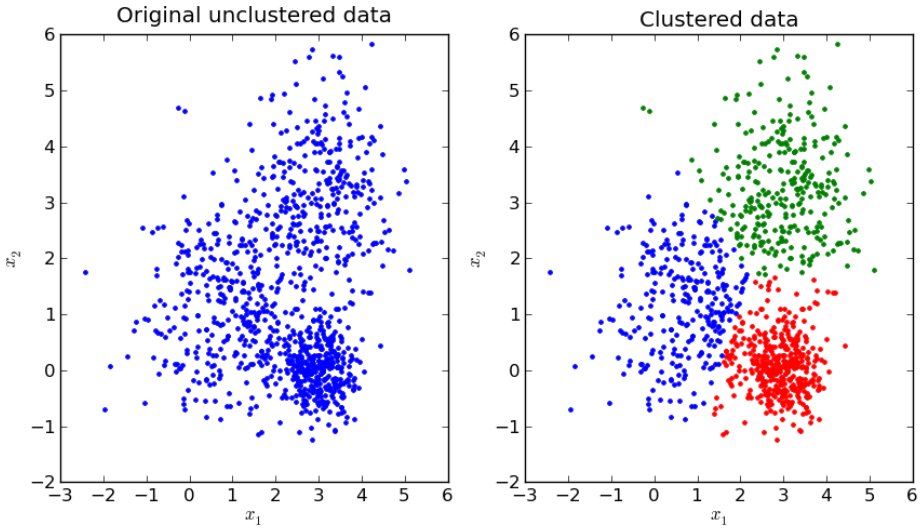

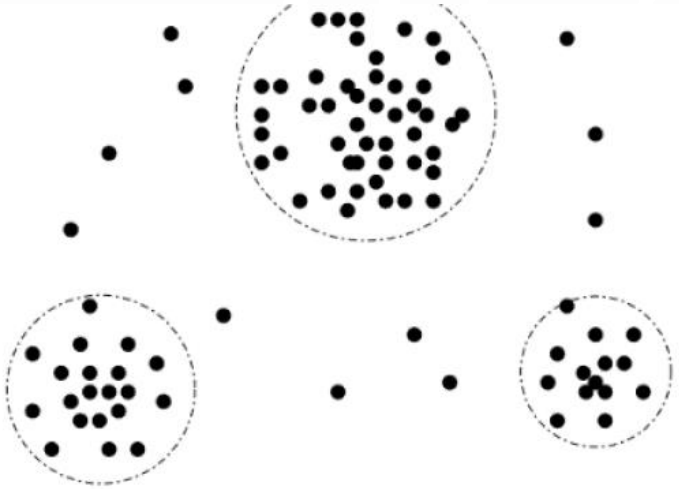

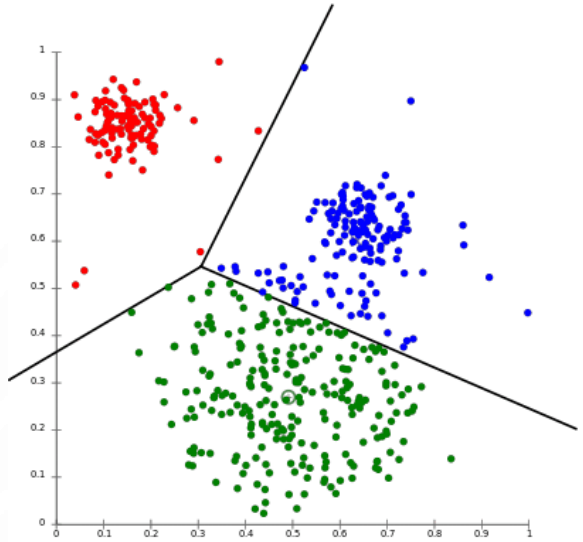

https://github.com/josenalde/datascience/blob/main/notebooks/nb_kmeans1.ipynb

ASPECTOS DE MACHINE LEARNING

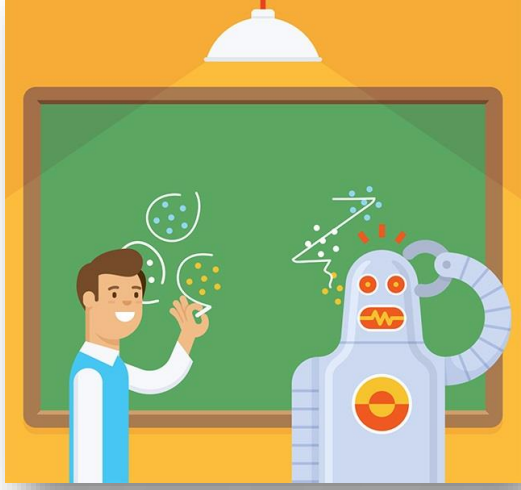

- **Classificação: supervisionado – conjuntos de treino / teste, métricas de avaliação mais bem definidas, por comparar com o *ground truth*, matriz de confusão etc.**

Métodos mais comuns: KNN, SVM, Árvore de Decisão, Redes Neurais

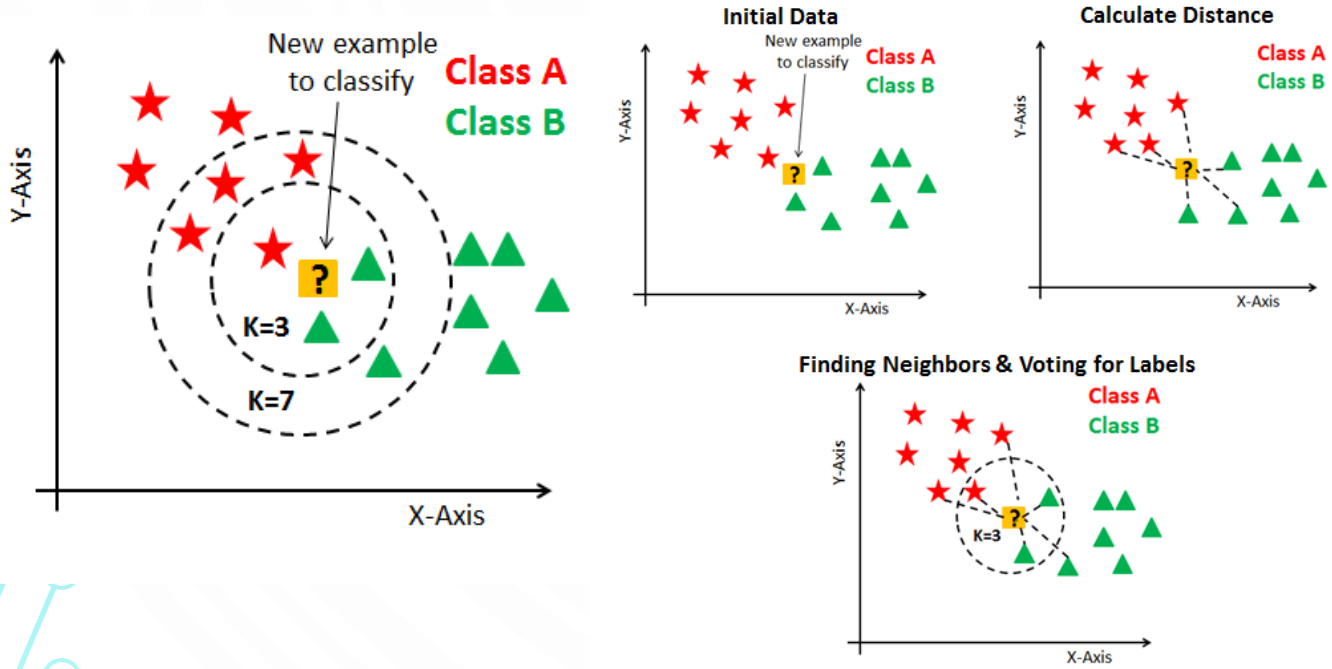

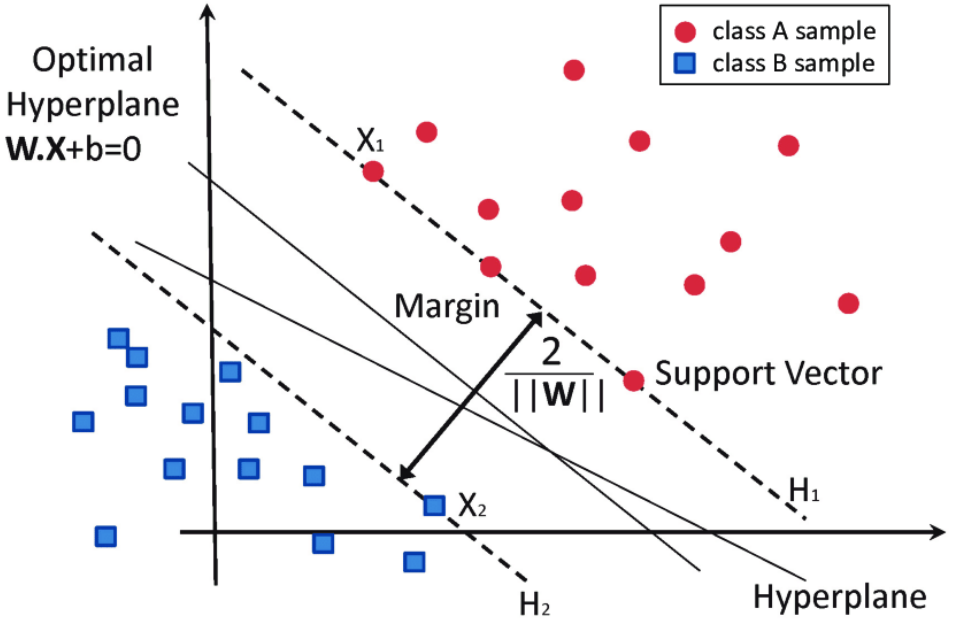

https://github.com/josenalde/datascience/blob/main/notebooks/nb_knn1.ipynb

https://github.com/josenalde/datascience/blob/main/notebooks/nb_svm1.ipynb

ASPECTOS DE MACHINE LEARNING

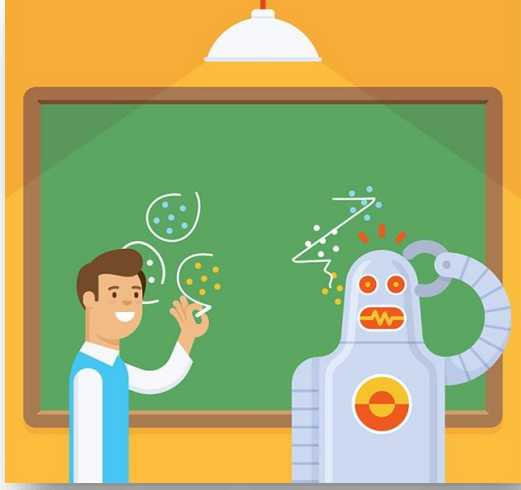

- **Classificação: supervisionado – conjuntos de treino / teste, métricas de avaliação mais bem definidas, por comparar com o *ground truth*, matriz de confusão etc.**

Métodos mais comuns: KNN, SVM, Árvore de Decisão, Redes Neurais

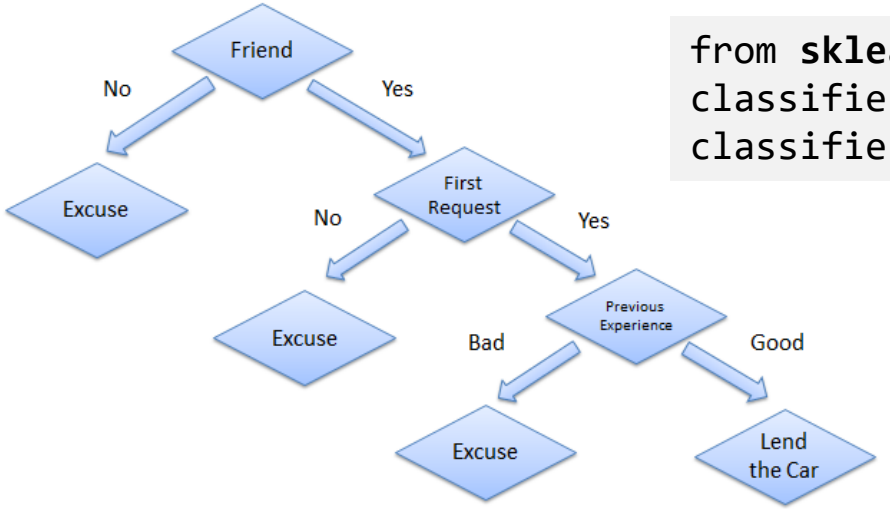


```
from sklearn.tree import DecisionTreeClassifier
classifier = DecisionTreeClassifier()
classifier.fit(X_train, y_train)
```

https://www.datacamp.com/community/tutorials/decision-tree-classification-python